Regularización

REGULARIZACION.

En los métodos de aprendizaje supervisado de regresión, se utilizan métodos de regularización para evitar hacer sobre ajuste en los modelos castigando la complejidad de los modelos. Iniciaremos por ver el método de Ridge.

Ridge

Función de costo de una regresión:

$$\sum_{i=1}^{N}(y_i - \hat{y}_i)^2 = \sum_{i=1}^{N}(y_i - \sum_{j=1}^{p} w_j x_{ij})^2$$

Función de costo con penalización Ridge:

$$\sum_{i=1}^{N}(y_i - \hat{y}_i)^2 = \sum_{i=1}^{N}(y_i - \sum_{j=1}^{p} w_j x_{ij})^2 + \underbrace{\lambda \sum_{j=1}^{p} w_j^2}_{\text{penalización Ridge}}$$

Donde:
N: Número de observaciones en el conjunto de datos
p: Número de variables explicativas en el modelo
w: Coeficientes obtenidos por la regresión

Un modelo de regresión se considera complejo en dos situaciones, cuando agregamos muchas variables explicativas, o bien, cuando la magnitud de los coeficientes es muy grande.

El método de regularización de Ridge o también llamada regularización `L2`, penaliza la complejidad del modelo basado en la magnitud de los coeficientes, para ello agrega a la función de costo de la regresión, la penalización equivalente a elevar al cuadrado los coeficientes obtenidos por la regresión.

El coeficiente de penalización conocido como λ, permite castigar valores grandes de coeficientes, encogiéndolos para que no crezcan.

Un coeficiente λ pequeño provocará que la penalización sea muy relajada y por lo tanto que los coeficientes crezcan. Por otro lado, un λ alto provoca una estricta penalización de tener coeficientes altos por lo que provocará que éstos se encojan hasta tener un valor muy cercano a 0 pero nunca de 0.

Encontrar el valor adecuado de λ depende del problema y de la experiencia de la persona que desarrolla el modelo.

La manera en la que los autores de este método sugieren seleccionar el valor de λ, es a través de una gráfica de trazabilidad de *ridge* en donde se grafican diferentes valores de λ utilizados, y el valor de los coeficientes obtenidos.

En la Figura 1 se muestra una gráfica de trazabilidad de λ con regularización Ridge. Cada línea representa el coeficiente asignado por una regresión a cada variable explicativa, y los diferentes valores que van tomando conforme se va modificando el valor de λ. Se puede ver que cuando λ tiene un valor muy bajo los coeficientes de cada variable prácticamente no se mueven, pero conforme el valor de λ aumenta, los coeficientes se van encogiendo acercándose al valor de 0.

Se considera que los coeficientes que tardan más en encogerse corresponden a las variables que aportan más información al modelo.

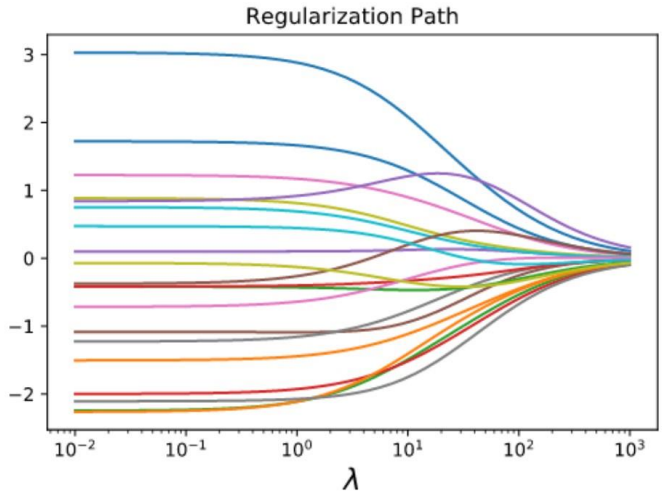

Fuente: https://www.cvxpy.org/examples/machine_learning/ridge_regression.html

Figura 1. Gráfica de trazabilidad de λ con regularización Ridge.

Ahora veremos otro de los métodos de regularización, Lasso.

Lasso

Función de costo de una regresión:

$$\sum_{i=1}^{N}(y_i - \hat{y}_i)^2 = \sum_{i=1}^{N}(y_i - \sum_{j=1}^{p} w_j x_{ij})^2$$

Función de costo con penalización Lasso:

$$\sum_{i=1}^{N}(y_i - \hat{y}_i)^2 = \sum_{i=1}^{N}(y_i - \sum_{j=1}^{p} w_j x_{ij})^2 + \underbrace{\lambda \sum_{j=1}^{p} |w_j|}_{\text{penalización Lasso}}$$

Donde:
N: Número de observaciones en el conjunto de datos
p: Número de variables explicativas en el modelo
w: Coeficientes obtenidos por la regresión

Al igual que el método *ridge*, la regularización del método *lasso* o también llamada `L1`, penaliza la complejidad de un modelo de regresión con base a la magnitud de los coeficientes que genera.

Lo que cambia en este método de regularización, es que en lugar de elevar al cuadrado el valor de los coeficientes, se obtiene el valor absoluto.

Al igual que con Ridge, Lasso penaliza coeficientes altos, sin embargo, en Lasso el valor de un coeficiente puede encogerse hasta llegar a ser `0`. Esta es la razón principal por la que la regularización de Lasso se ocupa también para selección de variables en un modelo, pues aquellas variables cuyos coeficientes sean `0`, no aportan información al modelo, por lo que la regularización los elimina.

Al igual que con Ridge, un λ pequeño implica que la regularización es muy laxa, no es está penalizando la complejidad, mientras que un λ alto provoca ser estrictos con la magnitud de los coeficientes y eliminar aquellos que no aportan información al modelo.

Encontrar el valor adecuado de λ depende del problema y de la experiencia de la persona que desarrolla el modelo.

Al igual que con Ridge, la manera en la que se sugiere seleccionar el valor de λ, es a través de una gráfica de trazabilidad de λ, en donde se grafican diferentes valores de λ utilizados y el valor de los coeficientes obtenidos.

En la Figura 2 se muestra una gráfica de trazabilidad de λ con regularización Lasso. Cada línea representa el coeficiente asignado por una regresión a cada variable explicativa, y los diferentes valores que van tomando conforme se va modificando el valor de λ. Se puede ver que cuando λ tiene un valor muy bajo, los coeficientes de cada variable prácticamente no se mueven, pero conforme el valor de λ aumenta, los coeficientes se van encogiendo, hasta que para cierto valor de λ la mayoría de los coeficientes se vuelven 0.

Se considera que los coeficientes que tardan más en encogerse corresponde a las variables que aportan más información al modelo.

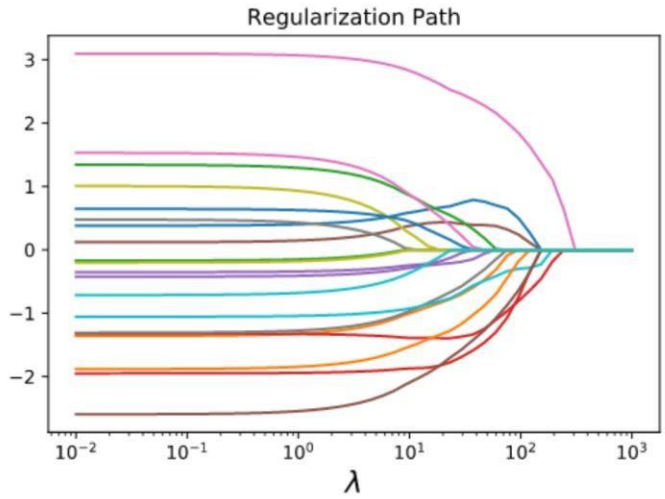

Fuente: https://www.cvxpy.org/examples/machine_learning/lasso_regression.html

Figura 2. Gráfica de trazabilidad de λ con regularización Lasso.

Desventajas

- Cuando la cantidad de observaciones `n` es menor que el número de variables `p` que contiene el conjunto de datos (`n<p`), Lasso selecciona a lo más, `n` variables de las posibles `p`.
- Cuando las variables forman parte de un grupo, Lasso tenderá a seleccionar una sola variable del grupo, dejando fuera al resto de variables de ese grupo.

Ahora conoceremos otro de los métodos de regularización que nos permite combinar Ridge y Lasso.

ElasticNet

Función de costo de una regresión:

$$\sum_{i=1}^{N}(y_i - \hat{y}_i)^2 = \sum_{i=1}^{N}(y_i - \sum_{j=1}^{p} w_j x_{ij})^2$$

Función de costo con penalización ElasticNet:

$$\sum_{i=1}^{N}(y_i - \hat{y}_i)^2 = \sum_{i=1}^{N}(y_i - \sum_{j=1}^{p} w_j x_{ij})^2 + \lambda_2 \sum_{j=1}^{p} w_j^2 + \lambda_1 \sum_{j=1}^{p} |w_j|$$

$$\sum_{i=1}^{N}(y_i - \hat{y}_i)^2 = \sum_{i=1}^{N}(y_i - \sum_{j=1}^{p} w_j x_{ij})^2 + \alpha(\sum_{j=1}^{p} w_j^2 + (1-\alpha)\sum_{j=1}^{p} |w_j|)$$

con $\alpha = \frac{\lambda_2}{\lambda_2 + \lambda_1}$

Donde:
N: Número de observaciones en el conjunto de datos
p: Número de variables explicativas en el modelo
w: Coeficientes obtenidos por la regresión

ElasticNet integra a la penalización tanto la penalización de Ridge como la de Lasso con una adecuación, por lo que agrega el parámetro α con el que ajusta las λ de la regularización de Lasso.

ElasticNet ocupa lo mejor de ambas regularizaciones y resuelve las desventajas de Lasso.

En esta regularización debido a que se integra la regularización de Lasso, también es posible tener coeficientes con valor de 0. De igual manera, una λ pequeña provoca tener un modelo laxo en penalización, y una λ grande penaliza coeficientes grandes.

En la Figura 3 se muestra una gráfica de trazabilidad de α, donde cada línea representa el coeficiente de una variable del conjunto de datos, nuevamente, cuando λ tiene valores pequeños los coeficientes no se penalizan, conforme λ va aumentando su valor, los coeficientes se van encogiendo hacia el 0, con posibilidad de ser 0.

Al igual que con Lasso, ElasticNet permite hacer selección de variables de acuerdo a la información que aportan al modelo.

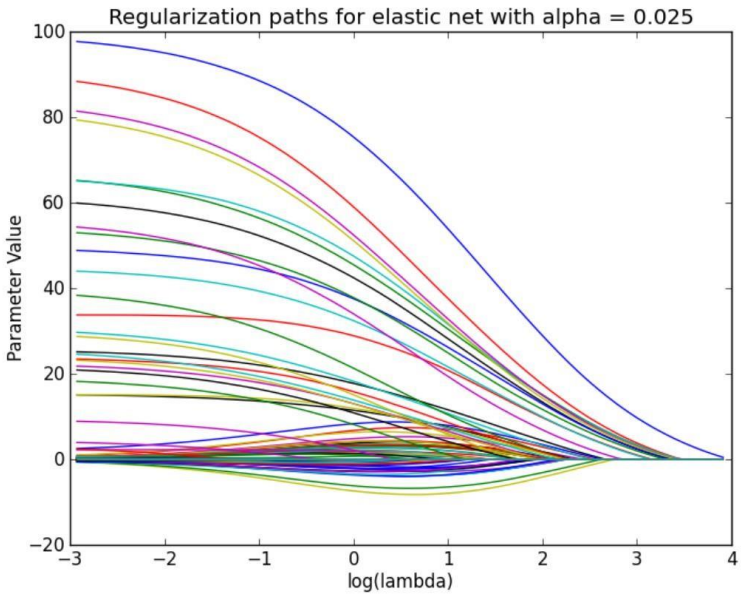

Fuente: https://github.com/ajmaurer/glmnet-python

Figura 3. Gráfica de trazabilidad de con regularización de ElasticNet.